

Análise de Desempenho e Valuation nas Quatro Principais Ligas Europeias: Uma Abordagem de Data Science (Temporada 24/25)

Felipe Parreiras Dias
Engenharia de Computação / CEFET-MG

5 de dezembro de 2025

1 Introdução

O futebol moderno transcendeu as quatro linhas, consolidando-se como uma indústria bilionária onde a tomada de decisão baseada em dados (*Data Analytics*) tornou-se um diferencial competitivo crucial. Clubes europeus investem massivamente na contratação de atletas, muitas vezes baseando-se em avaliações subjetivas que podem levar a ineficiências financeiras.

Este projeto insere-se no contexto do *Football Analytics*, investigando a relação entre o desempenho técnico individual e o valor de mercado dos jogadores nas quatro principais ligas da Europa: Bundesliga (Alemanha), Premier League (Inglaterra), La Liga (Espanha) e Serie A (Itália). A motivação do estudo reside na necessidade de democratizar ferramentas de *scouting* e *valuation*, permitindo identificar talentos subvalorizados e otimizar orçamentos.

A abordagem adotada combina técnicas de estatísticas individuais de jogadores, visualização de dados e aprendizado de máquina supervisionado para criar um modelo de análise comparativa, tanto intra-ligas quanto em um cenário global europeu.

2 Descrição do Problema

O fenômeno analisado é a precificação de ativos esportivos (jogadores) e sua correlação com a performance real em campo. Observa-se no mercado atual uma disparidade significativa de valores, onde a liga de origem muitas vezes inflaciona o preço de um atleta independentemente de suas estatísticas.

O escopo da pesquisa limita-se à temporada 2024/2025, focando nos jogadores ativos nas primeiras divisões da Alemanha, Inglaterra, Espanha e Itália. A escolha destas ligas justifica-se por concentrarem o maior volume financeiro e os dados mais robustos do futebol mundial.

Um dos principais desafios encontrados, e abordados neste trabalho, é a inconsistência e a volatilidade dos dados: transferências ocorrem durante a temporada (jogadores mudando de liga), e as nomenclaturas de clubes variam entre bases de dados (ex: "Man Utd" em tabelas oficiais versus "Manchester United" em bases estatísticas), exigindo um tratamento rigoroso de integridade referencial. Além disso, as características individuais de cada jogador se misturam com suas estatísticas em campo no momento

de sua precificação, o que deve ser analisado com cuidado para identificar os aspectos que mais contribuem para o aumento do valor de mercado.

3 Objetivos do Trabalho

3.1 Objetivo Geral

Desenvolver uma estrutura analítica de dados capaz de comparar o desempenho e o valor de mercado de jogadores europeus, identificando ineficiências de precificação e oportunidades de contratação.

3.2 Objetivos Específicos

- Coletar e tratar dados de jogadores e classificações das quatro ligas, solucionando inconsistências de nomenclatura.
- Desenvolver métricas de eficiência coletiva (Custo por Ponto) e individual (Índice Atlas).
- Aplicar algoritmos de Regressão Linear e Random Forrest para estimar o "Valor Justo" e classificar jogadores como super ou subvalorizados.
- Comparar o perfil econômico e tático entre as ligas.
- Criar uma ferramenta interativa de *scouting* para filtragem de jogadores por atributos específicos.

4 Metodologia

4.1 Ferramentas Utilizadas

O projeto foi desenvolvido em linguagem **Python**, utilizando o ambiente **Jupyter Notebook** para prototipagem rápida e análise exploratória. As principais bibliotecas foram:

- **Selenium:** Extração dos dados na web de forma automática.
- **Pandas:** Manipulação e estruturação dos dados tabulares.
- **NumPy:** Operações numéricas e vetoriais.

- **Scikit-learn:** Implementação do modelo de Regressão Linear.
- **Plotly Express e Seaborn:** Visualização de dados interativa e estática.

4.2 Extração dos Dados

Os dados foram obtidos através de *datasets* em formato CSV provenientes da plataforma **SofaScore**. Foram utilizados oito arquivos no total: quatro contendo estatísticas individuais detalhadas (valor, idade, notas, gols) e quatro contendo as tabelas de classificação (*standings*) oficiais de cada campeonato. Para a extração dos dataset's com os jogadores de cada campeonato, foi utilizada a biblioteca **Selenium**, preferida por fazer a extração de forma automática e navegação dentro do navegador de forma estratégica.

4.3 Tratamento e Preparação dos Dados

Uma etapa que demandou muita atenção durante a construção do projeto. Os dados brutos apresentavam natureza heterogênea, ou seja, não são uniformes, exigindo:

1. **Limpeza de Variáveis Numéricas:** Conversão de valores monetários (ex: "€124M" para 1.24×10^8) e tratamento de strings de idade ("3 de maio de 2004 (21)" para "21").
2. **Correção de Nomes de Times:** Criação de dicionários (*Hash Maps*) para padronizar nomes de equipes entre os arquivos de jogadores e tabelas (ex: mapear "Leverkusen" para "Bayer 04 Leverkusen").
3. **Gestão de Transferências:** Implementação de um algoritmo de correção para realocar jogadores transferidos (como Florian Wirtz ou Matthijs de Ligt) aos seus times de origem na temporada 24/25, garantindo a consistência das estatísticas.
4. **Tratamento de Missing Values:** Preenchimento de nulos com zero em estatísticas de jogo e remoção de registros inconsistentes.

4.4 Visualização dos Dados

Para a análise visual, utilizou-se **Seaborn** para matrizes de correlação e boxplots, e **Plotly** para gráficos de dispersão interativos.

- **Scatter Plots:** Escolhidos para relacionar duas variáveis contínuas (ex: Valor vs. Pontos), permitindo identificar *outliers* visuais.
- **Boxplots:** Utilizados para comparar a distribuição de preços entre as ligas, evidenciando a mediana e a dispersão (inflação).
- **Gráficos de barras:** Aplicados para visualizar as diferenças entre as ligas, no que diz respeito às suas características gerais (gols, assistências, média de notas, etc.).

4.5 Modelagem e Machine Learning

Nesta etapa, aplicaram-se técnicas de Aprendizado de Máquina Supervisionado para realizar o *valuation* (precificação justa) dos atletas. O experimento foi conduzido em duas fases: uma modelagem inicial utilizando **Regressão Linear** e uma modelagem avançada utilizando **Random Forest Regressor**.

A estrutura dos dados para o treinamento foi definida da seguinte forma:

- **Variável Alvo (Y):** Valor de Mercado (numérico).
- **Features (X):** Variáveis numéricas (Idade, Gols, Assistências, Dribles, Nota SofaScore) e variáveis categóricas (Posição e Liga), estas últimas tratadas via técnica de *One-Hot Encoding*.

A escolha pela transição da Regressão Linear para o Random Forest justificou-se por limitações teóricas do primeiro modelo frente à natureza dos dados. Enquanto a regressão linear pressupõe uma relação constante entre as variáveis, o mercado do futebol apresenta comportamentos não-lineares complexos, especificamente:

1. **A Curva da Idade:** A desvalorização de um atleta não é linear; ela tende a ser estável durante o auge físico e acelerada após os 30 anos. O Random Forest, baseado em árvores de decisão, adapta-se melhor a essas curvas sem necessidade de transformações polinomiais.
2. **Interações Condicionais:** O valor de uma estatística depende do contexto (ex: "Gols" são cruciais para atacantes, mas irrelevantes para defensores). O modelo de árvore consegue segmentar essas regras automaticamente.

A estratégia de análise baseou-se no cálculo dos **Resíduos** (R), definidos como a diferença entre o valor real de mercado e o valor predito pelo modelo ($R = Y_{real} - Y_{previsto}$). Esta métrica foi utilizada não como erro, mas como indicador de ineficiência de mercado: resíduos positivos sugerem supervalorização, enquanto negativos indicam oportunidades de investimento.

5 Repositório Utilizado

O código fonte, os datasets tratados e os notebooks de análise estão hospedados no GitHub. A organização do repositório segue a estrutura:

- **/jogadores:** Arquivos CSV com informações dos jogadores.
- **/tabela:** Tabela final dos campeonatos analisados nas temporadas 24/25.
- **/extracoes:** Scripts em **Python** de extração dos dados dentro do Sofascore.
- **/sem pasta:** Scripts divididos por liga (*analiseNomeDaLiga.ipynb*) e análise geral (*analiseComparativoGeral.ipynb*).

Link público: Repositório GitHub

6 Resultados e Discussões

A análise foi conduzida em duas frentes: uma verificação interna de cada liga seguida de uma comparação geral, incluindo estatísticas gerais dos torneios e também a união de todos os jogadores observados.

6.1 Análise interna de cada liga

Para cada uma das quatro ligas (Bundesliga, Premier League, La Liga e Serie A), foram aplicadas métricas para isolar o desempenho individual do contexto coletivo e avaliar a gestão de recursos.

6.1.1 O Índice Atlas e a Dependência Individual

Para identificar jogadores que sustentam o desempenho de suas equipes, desenvolveu-se o **Índice Atlas** (I_{Atlas}), referenciando o titã da mitologia grega conhecido por sua força e a famosa imagem carregando o mundo. A métrica calcula o diferencial entre a nota individual do atleta e a média da equipe:

$$I_{Atlas} = \text{NotaSofaScore}_{Jogador} - \overline{\text{NotaSofaScore}_{Time}} \quad (1)$$

Os resultados mostraram que o I_{Atlas} é frequentemente mais alto em equipes da metade inferior da tabela. Jogadores com $I_{Atlas} > 0.5$ nessas equipes foram classificados como "Atlas", indicando que sua performance individual está dissociada da má fase coletiva, tornando-os alvos primários para transferências.

	Nome	Time	Pos	Média das notas Sofascore	Índice_Atlas
0	Omar Marmoush	Eintracht Frankfurt	3	8.16	1.10
32	Florian Wirtz	Bayer 04 Leverkusen	2	7.68	0.60
19	Michael Olise	FC Bayern München	1	7.91	0.58
18	Joshua Kimmich	FC Bayern München	1	7.91	0.58
46	Xavi Simons	RB Leipzig	7	7.58	0.55
59	Franck Honorat	Borussia M'gladbach	10	7.43	0.49
60	Moritz Nicolas	Borussia M'gladbach	10	7.37	0.43
20	Harry Kane	FC Bayern München	1	7.73	0.40
89	Nadiem Amiri	1. FSV Mainz 05	6	7.32	0.38
75	Angelo Stiller	VfB Stuttgart	9	7.38	0.36

Figura 1: Exemplo dos jogadores "Atlas" da Bundesliga

6.1.2 Categorização de Ativos: Diamantes vs. Luxo

Com base na relação entre custo, desempenho e posição na tabela, os jogadores foram segmentados em duas categorias críticas:

- **Diamantes:** Jogadores com alta performance (Nota > 7.15) atuando em times posicionados abaixo do 10º lugar. Estes representam a máxima eficiência técnica.
- **Luxo Desperdiçado:** Jogadores com valor de mercado superior a €30 milhões atuando em equipes de baixa performance. A análise revelou uma concentração destes casos na Premier League, sugerindo ineficiência na alocação de recursos de clubes ingleses de médio porte.

6.1.3 Eficiência Financeira dos Clubes

A relação entre o Valor Total do Elenco e os Pontos Conquistados evidenciou a disparidade de eficiência. O gráfico de dispersão (Scatter Plot) permitiu identificar *outliers*: clubes que atingiram altas pontuações com orçamentos modestos (alta eficiência) versus clubes com gastos massivos e desempenho mediano. Ferramentas de *scouting* desenvolvidas no estudo, como o filtro de atributos e a busca nominal, validaram a existência de substitutos técnicos mais baratos dentro da própria liga para as posições mais carentes.




Figura 2: Gráfico de Pontos Conquistados X Investimento Total (€) da La Liga

A Figura 2 evidenciou um exemplo de time que soube investir o seu capital. O Barcelona foi um dos times com o investimento mais modesto do campeonato e, mesmo assim, conseguiu conquistar o título da La Liga 24/25.

6.2 Análise Comparativa Global

Ao unificar as bases de dados, foi possível traçar o perfil econômico e demográfico do futebol europeu.

6.2.1 A Inflação da Premier League

A comparação direta do "Custo da Nota SofaScore" confirmou a hipótese de inflação no mercado inglês. Um jogador com nota média 7.0 na Premier League possui um valor de mercado, em média, 40% a 60% superior a um jogador com a mesma nota na Serie A ou La Liga. Isso indica que o preço de um ativo é determinado tanto pela sua qualidade intrínseca quanto pelo poder de compra da liga onde atua.




Figura 3: Distribuição de valor de mercado por liga

A Figura 3 evidencia a diferença de valor de mercado médio entre os jogadores da premier league em comparação com as demais ligas. Isso indica que os melhores jogadores do mundo estão concentrados lá, porém, ao mesmo tempo, concentra muitos jogadores supervalorizados.

6.2.2 Demografia e Estilo de Jogo

A análise de distribuição de idade ("Onde jogam os jovens e os veteranos") confirmou a Bundesliga como a liga com menor média de idade, consolidando-se como um polo de desenvolvimento de talentos. Em contraste, a Serie A apresentou uma curva demográfica deslocada para a direita, indicando maior valorização da experiência. O comparativo de médias estatísticas por jogador (Gols, Assistências, Desarmes) revelou o "DNA" de cada liga, com a Bundesliga apresentando médias ofensivas superiores, enquanto La Liga destacou-se pela métrica de passes e posse.

6.2.3 Seleção Ideal e Atributos de Elite

A formação da "Seleção da Europa", baseada puramente em notas estatísticas, resultou em uma equipe heterogênea, provando que o talento de elite está distribuído entre as ligas, apesar da concentração financeira na Inglaterra. A mineração de texto nos atributos dos jogadores mais valiosos (Top 10% financeiro) revelou que características cognitivas e técnicas ("Visão de Jogo", "Passe", "Técnica") são mais frequentes na elite do que atributos puramente físicos, sugerindo que o mercado paga um prêmio pela inteligência de jogo.

6.3 Modelagem de Valuation: Justificativa de Preço de Ativos

Para determinar o "Preço Justo" e identificar oportunidades de mercado, comparou-se o desempenho de dois modelos: Regressão Linear Múltipla e Random Forest Regressor.

6.3.1 Correlação e Drivers de Valor

A matriz de correlação demonstrou que "Gols" e "Assistências" são os maiores impulsionadores de valor ($r > 0.6$). Crucialmente, a variável "Idade" apresentou correlação negativa, confirmando que o valor de mercado penaliza o envelhecimento, independentemente da manutenção da performance técnica.

6.3.2 Superioridade do Random Forest

O modelo **Random Forest** apresentou um coeficiente de determinação (R^2) significativamente superior à Regressão Linear. Esta superioridade técnica justifica-se por três fatores que o modelo linear falhou em capturar:

- 1. Não-Linearidade da Idade:** A relação entre idade e valor não é uma reta, mas uma curva (valorização até o auge físico, seguida de declínio). O Random Forest modelou essa curva com precisão, enquanto a regressão linear tendia a subestimar jovens talentos e superestimar veteranos.
- 2. Interações Condicionais:** O valor de uma estatística depende da posição (contexto). O Random Forest identificou automaticamente que "Desarmes" valorizam defensores, mas são irrelevantes para atacantes.

- 3. Resiliência a Outliers:** O modelo de floresta lidou melhor com os valores extremos dos "supercraques" (€100M+), evitando que estes distorcessem a predição para a média dos jogadores.

6.3.3 Análise de Resíduos: O Veredito do Modelo

A análise final baseou-se nos resíduos do Random Forest ($Valor_{Real} - Valor_{Justo}$).

- **Supervalorizados:** Jogadores com resíduos positivos altos. Geralmente atletas de grife em ligas inflacionadas, cujo desempenho estatístico não justifica o preço de etiqueta.
- **Subvalorizados (Oportunidades):** Jogadores com resíduos negativos. Identificou-se aqui um nicho de atletas de alta performance em ligas menos ricas (como Serie A) ou em times menores, que o modelo avaliou como "descontados" pelo mercado.




Figura 4: Preço de Mercado X Preço Justo Calculado (Via Random Forrest)

7 Conclusão e Considerações Finais

O trabalho atingiu seu objetivo principal ao estabelecer um fluxo de análise de dados robusto para o futebol europeu. Foi possível demonstrar que o valor de mercado de um jogador é uma variável complexa, influenciada tanto por sua performance técnica quanto pelo contexto econômico da liga onde atua.

A implementação dos dicionários de correção de nomes e o tratamento de transferências foram fundamentais para a confiabilidade dos resultados, mitigando um problema comum em *datasets* públicos. O modelo de Regressão Linear, embora simples, provou-se eficaz como ferramenta inicial de *valuation*, servindo de base para a detecção de anomalias de mercado.

Como limitações, cita-se a ausência de dados físicos, histórico de lesões, presença em seleções e a natureza estática da análise (recorte apenas da temporada passada). Trabalhos futuros podem expandir este escopo para incluir séries temporais, analisando a evolução do valor de mercado rodada a rodada, ou aplicar modelos mais complexos com um maior número de dados de cada jogador e informações sobre histórico das ligas.

Referências

- [1] SofaScore. *Database de Estatísticas de Futebol*. Acesso em: Dezembro de 2025. Disponível em: <https://www.sofascore.com/pt/>
- [2] Pandas Development Team. *pandas: data analysis tools for the Python programming language*. 2025.